

Predicción del incumplimiento del umbral sanitario de *Lepeophtheirus salmonis* en centros de cultivo mediante regresión logística binaria

Prediction of Exceeding the Sanitary Threshold of *Lepeophtheirus salmonis* in Aquaculture Facilities Using Binary Logistic Regression

¹Manolo Marcos Meza Rodriguez

Resumen:

La infestación por el piojo de mar *Lepeophtheirus salmonis* constituye uno de los principales desafíos sanitarios de la salmonicultura marina, debido a su impacto en el bienestar de los peces y a las exigencias regulatorias que establecen límites máximos de parásitos por individuo. El objetivo de este estudio fue predecir la probabilidad de exceder el umbral sanitario oficial —definido como más de tres hembras adultas de *L. salmonis* por pez— mediante un modelo de regresión logística binaria aplicado a registros operacionales de centros de cultivo reportados al Departamento de Pesca y Océanos de Canadá durante el periodo 2011–2024. La variable respuesta fue el incumplimiento del umbral sanitario, mientras que los predictores incluidos en el modelo final fueron el mes de muestreo, el número de corrales muestreados, la abundancia promedio por pez de estadios móviles no reproductivos machos de *L. salmonis* y la abundancia promedio por pez de estadios móviles del género *Caligus*. El modelo permitió identificar un fuerte efecto asociado a los estadios móviles de *L. salmonis machos*, cuyo incremento se relacionó con un aumento sustancial en la probabilidad de incumplimiento. Estos resultados demuestran la utilidad de la regresión logística binaria como herramienta aplicada para apoyar la vigilancia sanitaria en centros de cultivo y anticipar escenarios de riesgo regulatorio.

Palabras clave: Acuicultura, *Lepeophtheirus salmonis*, Regresión logística binaria, Sanidad en centros de cultivo, Umbral sanitario.

Abstract:

Sea-lice infestation caused by *Lepeophtheirus salmonis* remains one of the most critical health challenges in marine salmon aquaculture, due to its impact on fish welfare and the regulatory limits that establish maximum allowable parasite burdens per fish. The aim of this study was to predict the probability of exceeding the official sanitary threshold—defined as more than three adult female *L. salmonis* per fish—using a binary logistic regression model applied to operational farm records reported to Fisheries and Oceans Canada for the period 2011–2024. The response variable was the occurrence of threshold exceedance, while the final model included the following predictors: month of the year, number of pens sampled, average per-fish abundance of non-reproductive motile stages of *L. salmonis*, and the average per-fish abundance of motile stages of the genus *Caligus*. The model identified a strong effect associated with non-reproductive motile stages of *L. salmonis*, whose increases were strongly linked to a higher probability of threshold exceedance. These findings highlight the usefulness of binary logistic regression as a practical tool to support sanitary surveillance in aquaculture facilities and to anticipate regulatory risk scenarios.

Keywords: Aquaculture, *Lepeophtheirus salmonis*, Binary logistic regression, Sea lice, Sanitary threshold, Aquaculture health management.

1. Introducción

1.1 Contexto de la investigación internacional y nacional

La parasitosis cuyo nombre científico es *Lepeophtheirus salmonis*, comúnmente conocido como piojo de mar, constituye uno de los principales desafíos sanitarios de la salmonicultura marina a nivel global. En países con industria salmonera desarrollada, como Noruega, Canadá, Escocia y Chile, la presencia de este ectoparásito ha generado impactos significativos sobre el bienestar de los peces, la productividad de los centros de cultivo y los

costos de manejo sanitario. Debido a su capacidad reproductiva y a la facilidad con la que se dispersa en ambientes marinos, *L. salmonis* es objeto de estrictas regulaciones; por ello, se establecen límites máximos permitidos de parásitos por pez para minimizar riesgos sanitarios y ambientales. En particular, la normativa del Departamento de Pesca y Océanos de Canadá (DFO) establece un umbral sanitario crítico de tres hembras adultas por pez, cuyo incumplimiento implica medidas correctivas obligatorias en los centros de cultivo.

En el Perú, aunque *L. salmonis* no está presente debido a que la producción acuícola se desarrolla principalmente en ambientes continentales altoandinos y no marinos, el país enfrenta desafíos igualmente relevantes en sanidad de peces. La truchicultura peruana —especialmente en regiones como Junín, Puno y Huancavelica— experimenta un crecimiento sostenido y depende cada vez más de estrategias de vigilancia sanitaria para controlar enfermedades bacterianas, parasitarias y ambientales que pueden afectar la producción. Instituciones como SANIPES promueven estándares crecientes de control sanitario, lo que resalta la importancia de metodologías modernas de predicción y monitoreo epidemiológico. En este sentido, los avances internacionales en modelamiento predictivo para vigilancia de ectoparásitos ofrecen un marco conceptual valioso que puede ser adaptado o tomado como referencia para mejorar la gestión sanitaria en la acuicultura peruana.

1.2 Problema de investigación

La dinámica de infestación por *L. salmonis* presenta comportamientos complejos, influenciados por factores ambientales, estacionales y operacionales. A pesar del monitoreo obligatorio en Canadá, los centros de cultivo pueden superar en determinadas ocasiones el umbral de tres hembras adultas por pez, generando riesgos sanitarios que requieren respuesta inmediata. La variabilidad temporal y espacial del parásito hace difícil anticipar estos incrementos mediante observación directa, lo que motiva el uso de modelos estadísticos capaces de predecir probabilísticamente la ocurrencia de un incumplimiento sanitario. Por ello, surge la necesidad de desarrollar un modelo que permita anticipar la probabilidad de exceder el umbral regulatorio tomando como base únicamente información operacional rutinaria, es decir, variables disponibles en reportes periódicos de los centros de cultivo.

1.3 Trabajos realizados

La vigilancia, dinámica poblacional y gestión sanitaria del piojo de mar *Lepeophtheirus salmonis* han sido ampliamente estudiadas en la literatura internacional, especialmente en países con una industria salmoneera consolidada. Diversas revisiones han documentado la importancia epidemiológica y económica de estos ectoparásitos, subrayando que la salmoneicultura intensiva crea condiciones favorables para el aumento de la carga parasitaria y la transmisión tanto en peces cultivados como en poblaciones silvestres de salmones y truchas marinas (Costello, 2006; Torrissen et al., 2013). Estas síntesis han contribuido a posicionar a *L. salmonis*

como uno de los principales desafíos de sanidad en la acuicultura de salmónidos.

Desde el punto de vista biológico, se ha descrito en detalle el ciclo de vida de los piojos de mar y la influencia de factores ambientales como la temperatura y la salinidad sobre sus tasas de desarrollo, supervivencia y reproducción. Boxaspen (2006) revisa la biología y genética de *L. salmonis* y otros calígidos, mostrando cómo los distintos estadios (larvas planctónicas, copepoditos infectivos, chalimus, móviles y adultos) responden a las condiciones oceanográficas y al hospedero, lo que determina en gran medida la dinámica de infestación observada en centros de cultivo. Estos antecedentes apoyan el uso de conteos por estadio como indicadores operacionales del riesgo sanitario.

En relación con la vigilancia en centros de cultivo, Revie et al. (2005) evaluaron el efecto del agrupamiento entre corrales al monitorear la abundancia de piojos en salmones de granja. Mediante análisis estadísticos aplicados a datos de recuento, mostraron que la correlación entre peces de un mismo corral y entre corrales de una misma unidad de producción puede afectar de manera importante la precisión de las estimaciones y la interpretación de las tendencias de infestación, destacando la necesidad de considerar el diseño de muestreo y el esfuerzo de monitoreo al evaluar el estado sanitario de una granja. Estos resultados son especialmente relevantes para estudios que, como el presente, se basan en registros operacionales rutinarios.

Finalmente, se han desarrollado modelos de dinámica poblacional para describir la aparición y el control de brotes de piojo de mar en granjas específicas. Krkošek et al. (2010) analizaron la dinámica de brotes y control de *L. salmonis* en dos centros de cultivo en el archipiélago de Broughton (Columbia Británica), utilizando modelos sencillos de crecimiento poblacional y datos de tratamientos antiparasitarios. Sus resultados sugieren que el crecimiento exponencial de las poblaciones de piojos dentro de la granja, más que la inmigración continua desde el ambiente, es el principal motor de los brotes, y que el momento en que se aplican los tratamientos puede reducir de manera importante la presión de infección sobre salmones juveniles silvestres en las zonas adyacentes.

En conjunto, estos trabajos muestran que existe una base sólida de conocimiento sobre la biología, la vigilancia y la dinámica poblacional del piojo de mar en contextos de acuicultura intensiva. Sin embargo, la mayoría de los estudios se han centrado en abundancias continuas, tasas de crecimiento poblacional o impactos ecológicos,

mientras que son menos frecuentes los enfoques que formulan explícitamente el problema como la predicción de un evento binario de incumplimiento de un umbral sanitario regulatorio, enfoque que adopta el presente estudio.

1.4 Objetivo de la investigación

El presente estudio tiene como objetivo predecir la probabilidad de exceder el umbral sanitario oficial de más de tres hembras adultas de *Lepeophtheirus salmonis* por pez, utilizando un modelo de regresión logística binaria aplicado a registros operacionales de centros de cultivo recopilados por el Departamento de Pesca y Océanos de Canadá entre 2011 y 2024. El modelo se construyó a partir de variables operacionales de rutina, incluyendo el mes del año, el número de corrales muestreados, la abundancia promedio por pez de estadios móviles no reproductivos de *L. salmonis* machos y la abundancia promedio por pez de estadios móviles del género *Caligus*. El propósito es evaluar la utilidad práctica de este enfoque como herramienta predictiva para apoyar la vigilancia sanitaria en centros de cultivo y anticipar escenarios de riesgo regulatorio.

2. Antecedentes

2.1 Revisión bibliográfica

La modelación cuantitativa de la infestación por *Lepeophtheirus salmonis* en centros de cultivo se ha abordado mediante distintos tipos de modelos, que van desde enfoques epidemiológicos estocásticos hasta modelos estadísticos predictivos basados en conteos rutinarios de piojos. Estos antecedentes permiten situar el presente trabajo dentro de un campo en el que la regulación sanitaria suele basarse en umbrales de hembras adultas por pez, pero donde todavía son escasos los estudios que formulan explícitamente el problema como la predicción de un evento binario de “cumple/no cumple” un umbral regulatorio.

En primer lugar, Bravo et al. desarrollaron un modelo epidemiológico estocástico basado en estados y dependiente del tiempo para describir la dinámica de infestación de hembras adultas de *L. salmonis* en centros de cultivo de salmón del Este de Canadá. El modelo se formula como una cadena de Markov en tiempo discreto que representa la transición semanal entre distintos estados de infestación (libre, baja, alta, recuperación) a nivel de ciclo productivo, incorporando como covariables la temperatura superficial del mar, la exposición a granjas vecinas (mediante un kernel de distancia marina), la semana del ciclo, la semana de siembra y la aplicación de tratamientos. Los parámetros

se estiman mediante métodos de Monte Carlo vía cadenas de Markov (MCMC) y el desempeño se evalúa en términos de la probabilidad media de predecir correctamente las transiciones observadas, lo que proporciona una herramienta para entender y anticipar brotes de alta infestación. (Bravo et al., 2025).

Complementariamente, Elghafghuf et al. propusieron un enfoque basado en modelos estado-espacio multivariados para estimar la *presión de infestación* ejercida por las granjas sobre su entorno. En su estudio, los autores comparan diferentes formulaciones de modelos estado-espacio para series temporales de abundancia de piojos, separando explícitamente el proceso biológico subyacente del proceso de observación (conteo) y permitiendo incorporar fuentes de ruido y errores de medición. El objetivo central es cuantificar la presión de infestación interna (dentro del sitio) y externa (aportada por otros sitios) y evaluar qué método ofrece estimaciones más estables y útiles para la gestión sanitaria en acuicultura. (Elghafghuf, Vanderstichel, Hammell, & Stryhn, 2020).

Por otro lado, Stige et al. desarrollaron un modelo estadístico predictivo para el conteo de piojos —denominado “salmon lice prediction model”— con el fin de anticipar, a una o dos semanas vista, el número de piojos en distintos estadios parasitarios por jaula y por centro de cultivo. El modelo analiza de manera conjunta los conteos de hembras adultas, otros estadios móviles y estadios sésiles, utilizando como variables explicativas los conteos de la semana actual, un índice de presión de infestación, la temperatura del mar, el peso medio de los peces y la presencia de peces limpiadores (*wrasses*). Se trata de un modelo estadístico (de tipo bayesiano) orientado a la predicción operativa, capaz de explicar una fracción importante de la variabilidad en los conteos futuros de hembras adultas y cuantificar la incertidumbre asociada a dichas predicciones, lo que lo convierte en un antecedente directo para el uso de modelos predictivos en la toma de decisiones sanitarias. (Stige, Qviller, Viljugrein, & Tavorpanich, 2025).

Finalmente, el trabajo de Revie et al. constituye el referente fundamental en cuanto a disponibilidad de datos, ya que presenta el conjunto de datos “Sea lice infestation dataset for wild and farmed salmon populations on the Pacific coast of Canada (2001–2023)”. Este artículo describe en detalle la integración de múltiples fuentes de información (monitoreos de granjas, muestreos de peces silvestres, auditorías regulatorias) para construir una base de datos estandarizada con recuentos de piojos por pez, clasificados por estadio de

desarrollo, tipo de hospedero (salvaje o cultivado), zona geográfica y año. Además, documenta los procedimientos de limpieza, validación y estructuración de la base de datos, así como ejemplos de su uso para generar figuras y tablas descriptivas. Este dataset es particularmente relevante para el presente estudio, ya que proporciona la base empírica a partir de la cual se extraen las variables operacionales utilizadas en el modelo de regresión logística binaria. (Revie, Patanasatienkul, McEwan, & Stewardson, 2025).

En conjunto, estos antecedentes muestran que la literatura reciente sobre piojos de mar en acuicultura ha avanzado significativamente en la modelación de la dinámica de abundancias y de la presión de infestación mediante modelos epidemiológicos, estado-espacio y modelos predictivos bayesianos. Sin embargo, se observa que la mayoría de los trabajos se centran en conteos continuos o categorización de estados de infestación, mientras que son menos frecuentes los estudios que formulan explícitamente el problema como la predicción de un evento binario de incumplimiento de un umbral sanitario regulatorio, tal como se propone en el presente artículo mediante un modelo de regresión logística binaria.

3. Metodología

3.1 Componentes de la regresión logística binaria

La regresión logística binaria es un método estadístico utilizado para modelar variables respuestas dicotómicas, permitiendo estimar la probabilidad de ocurrencia de un evento a partir de un conjunto de variables explicativas. Su formulación se basa en tres elementos fundamentales: una variable respuesta binaria, una función de enlace logit que relaciona la probabilidad del evento con el predictor lineal y un predictor lineal que integra las covariables del modelo.

En el presente estudio, la variable respuesta corresponde al incumplimiento del umbral sanitario de *Lepeophtheirus salmonis*, definido como un evento binario que toma el valor 1 cuando la abundancia promedio por pez de hembras adultas supera las tres unidades, según la normativa del Departamento de Pesca y Océanos de Canadá, y 0 en caso contrario. La regresión logística modela la probabilidad de incumplimiento mediante la función logit:

$$\text{logit}(p_i) = \log\left(\frac{p_i}{1 - p_i}\right) = \eta_i,$$

El **predictor lineal** se construyó a partir de información operacional rutinaria reportada por los centros de cultivo. Se incluyeron cuatro covariables con relevancia biológica y operativa:

Mes del año (**month**): variable categórica que captura la estacionalidad de la infestación, considerando que las poblaciones de *L. salmonis* presentan fluctuaciones mensuales asociadas a factores ambientales y productivos.

Número de corrales muestreados (**num_pens_sampled**): indicador del esfuerzo de muestreo y de la estructura operativa del centro, que puede influir en la representatividad de las estimaciones de abundancia parasitaria.

Abundancia promedio por pez de estadios móviles no reproductivos de *L. salmonis* (**lep_motile_ab**): incluye preadultos y machos, expresados como número promedio por pez. Estos estadios móviles anteceden a la fase reproductiva y actúan como un indicador temprano de riesgo, debido a su asociación con aumentos posteriores en la abundancia de hembras adultas.

Abundancia promedio por pez de estadios móviles de *Caligus spp.* (**cal_motile_ab**): se refiere a otro parásito, que puede reflejar condiciones ambientales favorables a la infestación.

Cada coeficiente del modelo describe el efecto de su respectivo predictor sobre los **odds de incumplimiento** del umbral sanitario, manteniendo constantes las demás variables. En este sentido, la regresión logística binaria constituye una herramienta adecuada para transformar información operacional rutinaria en estimaciones probabilísticas que apoyan la vigilancia sanitaria en centros de cultivo.

3.2 Descripción de los datos

Los datos utilizados en este estudio provienen de los registros operacionales de centros de cultivo de salmón reportados al Department of Fisheries and Oceans (DFO) de Canadá para el periodo 2011–2024. Estos registros forman parte de los programas de vigilancia sanitaria obligatoria e incluyen, para cada centro y fecha de muestreo, información estandarizada sobre la abundancia promedio por pez de distintos estadios del piojo de mar *Lepeophtheirus salmonis* y del género *Caligus spp.*, así como antecedentes básicos del muestreo realizado en el centro. El conjunto de datos analizado corresponde a varios miles de observaciones, lo que proporciona una cobertura temporal y espacial amplia del sistema productivo.

Para este trabajo se consideraron las siguientes variables:

Mes del muestreo: identifican el momento en que se realizó el monitoreo en cada centro.

Número de corrales muestreados: cantidad de unidades de cultivo incluidas en el muestreo en cada visita.

Abundancia promedio por pez de estadios móviles no reproductivos de *L. salmonis*: número promedio por pez de estadios móviles preadultos y machos.

Abundancia promedio por pez de estadios móviles de *Caligus spp.*: número promedio por pez de estadios móviles pertenecientes a este género.

Abundancia promedio por pez de hembras adultas de *L. salmonis*: utilizada para definir el cumplimiento del umbral sanitario.

A partir de la abundancia de hembras adultas se construyó la variable respuesta binaria del modelo, que indica el estado sanitario del centro en cada muestreo. En particular, se definió como “incumplimiento” toda situación en que la abundancia promedio por pez de hembras adultas de *L. salmonis* excedió las tres unidades, de acuerdo con el umbral regulatorio establecido por el DFO, y como “cumplimiento” los casos en que dicho valor fue menor o igual a tres.

Las variables predictoras incluidas en el modelo de regresión logística binaria fueron: el mes del muestreo (tratado como variable categórica para capturar la estacionalidad del parásito), el número de corrales muestreados en cada visita y las abundancias promedio por pez de estadios móviles no reproductivos de *L. salmonis* y de estadios móviles de *Caligus spp.* Estas variables corresponden a información operacional de rutina disponible en los reportes periódicos de los centros de cultivo.

El preprocesamiento de la base de datos se orientó a preservar su carácter operacional. Se seleccionaron únicamente las variables relevantes para el objetivo del estudio y se verificó la coherencia interna de los registros. Los valores faltantes en las variables de abundancia se interpretaron como ausencia de detección en el muestreo y se trataron como cero, criterio consistente con la práctica habitual en análisis operacionales. Adicionalmente, el mes del muestreo se codificó explícitamente como factor para permitir la estimación de efectos específicos por mes en el modelo. No se aplicaron filtros adicionales por valores extremos, dado que los conteos de parásitos y los tamaños de muestreo se mantuvieron dentro de rangos considerados

plausibles en el contexto de monitoreos sanitarios de centros de cultivo.

En conjunto, la base de datos empleada representa un sistema de vigilancia sanitaria de largo plazo, basado en información rutinaria de centros de cultivo, lo que permite evaluar el desempeño de la regresión logística binaria en un contexto aplicado y directamente relevante para la gestión de riesgos asociados a *L. salmonis*.

3.3 Marco teórico

La regresión logística binaria pertenece a la familia de los modelos lineales generalizados, y se utiliza cuando la variable respuesta es dicotómica. Sea Y_i la variable que indica el estado sanitario en la i -ésima observación, donde $Y_i = 1$ representa el incumplimiento del umbral sanitario y $Y_i = 0$ el cumplimiento. Condicionalmente al vector de covariables $\mathbf{x}_i$, se asume que:

$$Y_i | \mathbf{x}_i \sim \text{Bernoulli}(p_i)$$

$$\mathbb{E}(Y_i | \mathbf{x}_i) = p_i \quad \text{Var}(Y_i | \mathbf{x}_i) = p_i(1 - p_i)$$

donde p_i denota la probabilidad de incumplimiento en la observación i .

El modelo logístico especifica una relación entre p_i y un predictor lineal η_i mediante la función de enlace logit:

$$\text{logit}(p_i) = \log\left(\frac{p_i}{1 - p_i}\right) = \eta_i$$

de modo que la probabilidad puede escribirse como

$$p_i = \frac{\exp(\eta_i)}{1 + \exp(\eta_i)}$$

El predictor lineal adopta la forma

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik}$$

donde β_0 es el intercepto, $\beta_1, \dots, \beta_k$ son los coeficientes asociados a las covariables x_{ij} , y k es el número de predictores incluidos en el modelo. En este contexto, cada coeficiente β_j representa el cambio en el logaritmo de la razón de probabilidades (log-odds) de incumplimiento asociado a un incremento unitario en la covariable correspondiente, manteniendo constantes las demás. La cantidad $\exp(\beta_j)$ se interpreta como la **razón de odds** (odds ratio) de incumplimiento para dicho incremento.

La estimación de los parámetros $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_k)^\top$ se realiza mediante el método de **máxima verosimilitud**. La función de verosimilitud para una muestra independiente de tamaño n viene dada por

$$L(\boldsymbol{\beta}) = \prod_{i=1}^n p_i^{Y_i} (1 - p_i)^{1-Y_i},$$

y su logaritmo,

$$\ell(\beta) = \sum_{i=1}^n [Y_i \log(p_i) + (1 - Y_i) \log(1 - p_i)],$$

se maximiza numéricamente mediante algoritmos iterativos, típicamente el procedimiento de iteratively reweighted least squares (IRLS), equivalente al método de Fisher scoring. Bajo condiciones regulares, los estimadores de máxima verosimilitud $\hat{\beta}$ son asintóticamente normales, lo que permite construir intervalos de confianza e implementar contrastes de hipótesis para cada parámetro.

El ajuste global del modelo puede evaluarse mediante la desviación, definida como

$$D = -2[\ell(\hat{\beta}) - \ell_{\text{sat}}],$$

donde ℓ_{sat} es el logaritmo de la verosimilitud del modelo saturado. Reducciones importantes en la desviación respecto al modelo nulo indican que las covariables incluidas explican una proporción sustancial de la variabilidad en la respuesta.

En conjunto, el marco teórico de la regresión logística binaria proporciona una base sólida para modelar la probabilidad de incumplimiento del umbral sanitario a partir de covariables biológicas y operacionales, permitiendo interpretar los efectos en términos epidemiológicos mediante razones de odds y evaluar rigurosamente la capacidad predictiva del modelo.

Para cada coeficiente β_k estimado se puede construir un intervalo de confianza al 95% usando la aproximación normal:

$$IC_{95\%}(\beta_k) = \hat{\beta}_k \pm z_{0.975} \cdot SE(\hat{\beta}_k).$$

y el intervalo correspondiente para la razón de odds es:

$$IC_{95\%}(OR_k) = \left(\exp(\hat{\beta}_k - z_{0.975} SE(\hat{\beta}_k)), \exp(\hat{\beta}_k + z_{0.975} SE(\hat{\beta}_k)) \right).$$

Si el intervalo para OR_k **no incluye 1**, se concluye que la covariable asociada tiene un efecto estadísticamente significativo sobre la probabilidad de incumplir el umbral sanitario, al nivel de significación considerado.

4. Aplicación y resultados

4.1 Aplicación de la regresión logística binaria

El modelo de regresión logística binaria se ajustó utilizando el software R, tomando como variable respuesta el incumplimiento del umbral sanitario de *Lepeophtheirus salmonis* (1 = excede más de tres hembras adultas por pez, 0 = por debajo del umbral).

Como variables explicativas se consideraron el mes del muestreo, el número de corrales muestreados y las abundancias promedio por pez de estadios móviles no reproductivos de *L. salmonis* y de estadios móviles del género *Caligus spp.*

Formulación del modelo de regresión logística binomial

Variable respuesta:

$$Y_i = \begin{cases} 1, & \text{La abundancia de hembras adultas de } L. \text{ salmonis por pez excede el umbral } (> 3). \\ 0, & \text{La abundancia de hembras adultas no excede el umbral.} \end{cases}$$

Variables predictoras:

X_1 (month): Se modela como un factor con una categoría de referencia (por ejemplo, enero), y el resto de meses se incluyen mediante variables indicadoras.

X_2 (num_pens_sampled): Número de corrales para las muestras en la visita.

X_3 (lep_motile_ab): Abundancia promedio por pez de estadios móviles machos no reproductivos de *L. salmonis*.

X_4 (cal_motile_ab): Abundancia promedio por pez de estadios móviles de *Caligus spp.*

$$\eta_i = \beta_0 + \beta_{\text{mes}(i)} X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4.$$

La regresión logística binaria utiliza como función de enlace el **logit**:

$$\log\left(\frac{\pi_i}{1 - \pi_i}\right) = \eta_i$$

Donde se obtiene la probabilidad de incumplimiento del umbral sanitario:

$$\pi_i = \frac{\exp(\eta_i)}{1 + \exp(\eta_i)}$$

$$P(Y = 1) = \hat{\pi} = \frac{\exp(-6.564 - 0.913 x_{11} - 0.745 x_{12} - 0.779 x_{13} - 1.049 x_{14} - 0.990 x_{15} - 1.022 x_{16} - 0.780 x_{17} - 0.333 x_{18} - 0.779 x_{13} - 1.049 x_{14} - 0.990 x_{15} - 1.022 x_{16} - 0.780 x_{17} - 0.333 x_{18} + 0.418 x_{18} - 0.137 x_{19} + 0.072 x_{110} - 0.069 x_{111} + 1.063 x_2 - 0.143 x_3) + 0.418 x_{18} - 0.137 x_{19} + 0.072 x_{110} - 0.069 x_{111} + 1.063 x_2 - 0.143 x_3)}{1 + \exp(-6.564 - 0.913 x_{11} - 0.745 x_{12} - 0.779 x_{13} - 1.049 x_{14} - 0.990 x_{15} - 1.022 x_{16} - 0.780 x_{17} - 0.333 x_{18} - 0.779 x_{13} - 1.049 x_{14} - 0.990 x_{15} - 1.022 x_{16} - 0.780 x_{17} - 0.333 x_{18} + 0.418 x_{18} - 0.137 x_{19} + 0.072 x_{110} - 0.069 x_{111} + 1.063 x_2 - 0.143 x_3)}$$

Para cada coeficiente β_k estimado se puede construir un intervalo de confianza al 95% usando la aproximación normal:

$$IC_{95\%}(\beta_k) = \hat{\beta}_k \pm z_{0.975} \cdot SE(\hat{\beta}_k).$$

Tabla 1. coeficientes de regresión y sus respectivos intervalos de confianza al 95%.

	$\hat{\beta}$	IC_inf_95	IC_sup_95
Intercept	-6.564	-7.111	-6.016
Febrero	-0.913	-1.653	-0.174
Marzo	-0.745	-1.390	-0.100
Abril	-0.779	-1.458	-0.100
Mayo	-1.049	-1.798	-0.300
Junio	-0.990	-1.872	-0.108
Julio	-1.022	-1.803	-0.241
Agosto	-0.780	-1.412	-0.148
Setiembre	-0.333	-0.895	0.229
Octubre	0.418	-0.115	0.951
Noviembre	-0.137	-0.707	0.432
Diciembre	0.072	-0.530	0.673
Número de corrales	-0.069	-0.126	-0.012
L. salmonis machos	1.063	1.002	1.124
Número de Caligus	-0.143	-0.222	-0.063

Fuente: Elaboración propia.

Los resultados asociados a los meses del año muestran que, en comparación con enero, la probabilidad de superar el umbral sanitario es claramente menor durante febrero, marzo, abril, mayo, junio, julio y agosto. En cambio, para setiembre, octubre, noviembre y diciembre los intervalos de confianza al 95 % incluyen tanto valores compatibles con aumento como con disminución del riesgo, por lo que con estos datos no se puede afirmar con seguridad que la probabilidad sea mayor o menor que en enero, aunque en octubre y diciembre se observa una ligera tendencia hacia un riesgo más alto. En cuanto a las variables continuas, se observa que, manteniendo las demás condiciones constantes, mientras más corrales se muestrean, menor es la probabilidad de incumplir el umbral sanitario, lo que sugiere que un mayor esfuerzo de monitoreo se asocia con mejores resultados sanitarios. Por otro lado, la abundancia de estadios móviles no reproductivos de *L. salmonis* (machos) está fuertemente relacionada con un mayor riesgo de superar el límite de tres hembras adultas por pez: a medida que este indicador aumenta, también lo hace la probabilidad de incumplimiento. Finalmente, una mayor abundancia de *Caligus* spp. se asocia con una probabilidad menor de exceder el umbral, lo que podría reflejar diferencias en la forma en que las distintas especies de copépodos parásitos afectan a los peces en los centros de cultivo.

Prueba de significación del modelo.

Formulación de hipótesis:

H_0 :El modelo logístico binario se ajusta a los datos

H_1 :El modelo logístico binario no se ajusta a los datos

Prueba estadística:

La desviación se distribuye:

$$D = \chi^2_c = 1726.1, \quad gl = 18610.$$

Decisión estadística:

$$\chi^2_{0.95,18610} = \text{qchisq}(0.95,18610)$$

$$D = 1726.1 \ll \chi^2_{0.95,18610},$$

no se rechaza H_0 .

Equivalente en términos de p -valor:

$$p\text{-valor} = 1 - \text{pchisq}(1726.1,18610) \approx 1.$$

Por lo tanto, **no se rechaza** H_0 .

Conclusión.

Con un nivel de significación de 0.05, no hay evidencia estadística para rechazar que el modelo de regresión logística binaria se ajusta adecuadamente a los datos.

Prueba de significación de los coeficientes de regresión

En la regresión logística binaria se evalúa, para cada coeficiente β_i , si su efecto sobre la respuesta es estadísticamente distinto de cero. Para ello se plantea la prueba:

- Hipótesis nula:

$$H_0: \beta_i = 0$$

- Hipótesis alternativa:

$$H_1: \beta_i \neq 0$$

El estimador $\hat{\beta}_i$ obtenido por máxima verosimilitud es aproximadamente normal, por lo que el estadístico de prueba es

$$Z_c = \frac{\hat{\beta}_i - \beta_i}{S_{\hat{\beta}_i}},$$

donde $S_{\hat{\beta}_i}$ es el error estándar del estimador $\hat{\beta}_i$. Bajo H_0 y para muestras grandes, $Z_c \sim N(0,1)$.

Para un nivel de significancia $\alpha = 0,05$, el valor crítico bilateral se obtiene de la distribución normal estándar:

Tabla 1. Prueba de significación de los coeficientes de regresión.

	Beta	Valor_z	p_valor
Intercept	-6.5636	-23.4959	0.0000000
Febrero	-0.9135	-2.4214	0.0154600
Marzo	-0.7450	-2.2634	0.0236100
Abril	-0.7786	-2.2474	0.0246100
Mayo	-1.0491	-2.7451	0.0060500
Junio	-0.9898	-2.1999	0.0278100
Julio	-1.0221	-2.5654	0.0103100
Agosto	-0.7798	-2.4189	0.0155700
Setiembre	-0.3330	-1.1612	0.2456000
Octubre	0.4183	1.5386	0.1239000
Noviembre	-0.1371	-0.4719	0.6370000
Diciembre	0.0717	0.2335	0.8153000
Número de corrales	-0.0686	-2.3610	0.0182300
L. salmonis machos	1.0630	34.0401	0.0000000
Número de Caligus	-0.1429	-3.5169	0.0004366

Fuente: Elaboración propia.

Para un nivel de significancia $\alpha = 0,05$, se puede afirmar que no todas las variables explican presencia de más de 3 piojos de mar por salmón, pero tomaremos en cuenta la prueba de significación del modelo.

Calculo del R cuadrado ajustado

$R^2 = 77.39$, esto quiere decir que la desviación al agregar las variables predictoras (mes, machos, género Caligus) disminuye en 77.39%.

Razón de odds

Para un coeficiente β_k , la **razón de odds (OR)** asociada es:

$$OR_k = \exp(\beta_k).$$

En este estudio los resultados son los siguientes:

y el intervalo correspondiente para la razón de odds es:

$$IC_{95\%}(OR_k) = \left(\exp\left(\hat{\beta}_k - z_{0.975} SE(\hat{\beta}_k)\right), \exp\left(\hat{\beta}_k + z_{0.975} SE(\hat{\beta}_k)\right) \right).$$

Tabla 2. Razones de odds e intervalos de confianza al 95%.

	OR	IC_inf_95	IC_sup_95
Intercept	0.0014	0.0008	0.0024
Febrero	0.4011	0.1915	0.8402
Marzo	0.4748	0.2491	0.9050
Abril	0.4590	0.2328	0.9052
Mayo	0.3503	0.1656	0.7408
Junio	0.3717	0.1539	0.8977

Julio	0.3598	0.1648	0.7857
Agosto	0.4585	0.2437	0.8625
Setiembre	0.7168	0.4086	1.2574
Octubre	1.5193	0.8918	2.5885
Noviembre	0.8719	0.4933	1.5409
Diciembre	1.0743	0.5886	1.9608
Número de corrales	0.9337	0.8819	0.9884
L. salmonis machos	2.8951	2.7232	3.0778
Número de Caligus	0.8669	0.8005	0.9387

Fuente: Elaboración propia.

Los resultados por mes indican que, en comparación con enero, la probabilidad de superar el umbral sanitario de tres hembras adultas de *L. salmonis* por pez es claramente más baja durante febrero, marzo, abril, mayo, junio, julio y agosto. En términos simples, en esos meses el riesgo de pasarse del límite suele ser aproximadamente entre un tercio y la mitad del que se observa en enero. En cambio, para setiembre, octubre, noviembre y diciembre los datos son más inciertos: los intervalos de confianza son amplios y permiten tanto una ligera disminución como un posible aumento del riesgo respecto a enero. Por ello, con la información disponible no se puede afirmar con seguridad que en esos meses la probabilidad sea mayor o menor que en enero, aunque en octubre y diciembre se observa una tendencia a que el riesgo sea algo más alto.

En cuanto a las variables continuas, se observa que, manteniendo constantes las demás condiciones, cuanto mayor es el número de corrales muestreados, menor es la probabilidad de incumplir el umbral sanitario; es decir, un mayor esfuerzo de muestreo se asocia con mejores resultados sanitarios. Por el contrario, la abundancia de estadios móviles no reproductivos de *L. salmonis* (machos) está fuertemente relacionada con un riesgo mucho mayor de superar el límite de tres hembras adultas por pez: al aumentar este indicador, la probabilidad de incumplimiento crece de forma muy marcada, llegando a ser casi unas tres veces mayor para incrementos unitarios en esta variable. Finalmente, una mayor presencia de copépodos del género *Caligus* se asocia con una probabilidad algo menor de exceder el umbral, lo que sugiere que la dinámica de infestación no es la misma para todas las especies de parásitos presentes en los centros de cultivo.

Tabla 3. Desempeño del modelo de regresión logística en el conjunto de prueba.

Métrica	Valor
Tasa de acierto (%)	98.10
Tasa de error (%)	1.90

Sensibilidad (TVP) (%)	74.21
Especificidad (TVN) (%)	99.57
Tasa de falso positivo	0.43
Tasa de falso negativo	25.79
Valor predictivo positivo (%)	91.47
Valor predictivo negativo (%)	98.43

Fuente: Elaboración propia

En el conjunto de prueba, el modelo de regresión logística mostró un desempeño global muy alto, con una tasa de acierto del 98.10 % y una tasa de error del 1.90 %. La sensibilidad alcanzó un 74.21 %, lo que indica que aproximadamente tres de cada cuatro episodios en los que se supera el umbral sanitario son correctamente identificados por el modelo como “incumplimiento”. Por su parte, la especificidad fue de 99.57 %, de modo que casi todos los registros que se mantienen por debajo del umbral son clasificados correctamente como “cumple”.

En términos de errores, la tasa de falsos positivos fue muy baja (0.43 %), es decir, son muy pocos los casos en los que el modelo señala “incumplimiento” cuando en realidad el centro se encuentra dentro de los límites permitidos. La tasa de falsos negativos fue del 25.79 %, lo que implica que alrededor de una cuarta parte de los episodios de incumplimiento no son detectados por el modelo y se clasifican como si cumplieran. Finalmente, los valores predictivos muestran que, cuando el modelo predice que se incumple el umbral, esto es cierto en el 91.47 % de los casos, mientras que cuando predice que se cumple, dicha clasificación es correcta en el 98.43 % de las observaciones. En conjunto, estos resultados indican que el modelo es muy fiable para confirmar el buen estado sanitario y mantiene una capacidad de detección de incumplimientos adecuada para fines de vigilancia.

Predicción del modelo

Se desea saber cuáles son los meses donde se pueda superar el umbral sanitario, teniendo en cuenta lo siguiente, se realizará el muestreo en dos corrales, se espera encontrar siete machos de la especie *L.salmonis* por pez y cinco del estadio móvil *Caligus spp.* por pez.

$$\eta_{ej} = \beta_0 + \beta_i \mathbb{I}(\text{month} = i) + \beta_{pens} \cdot 2 + \beta_{Lmot} \cdot 7 + \beta_{Cal} \cdot 5$$

$$\hat{p}_{ej} = \frac{1}{1 + \exp(-\eta_{ej})}$$

Tabla 4. Predicciones del modelo


Mes	Probabilidad	Predicción
-----	--------------	------------

Enero	0.5064747	Si excede
Febrero	0.2916109	No excede
Marzo	0.3276006	No excede
Abril	0.3202333	No excede
Mayo	0.2644076	No excede
Junio	0.2761062	No excede
Julio	0.2696848	No excede
Agosto	0.3199662	No excede
Setiembre	0.4238339	No excede
octubre	0.6092534	Si excede
noviembre	0.4722246	No excede
diciembre	0.5243789	Si excede

Fuente: Elaboración propia

Entonces en el escenario hipotético correspondiente a dos corrales muestreados, una abundancia promedio de siete machos de *Lepeophtheirus salmonis* por pez y cinco estadios móviles de *Caligus spp.* por pez. El modelo de regresión logística binaria estimó una probabilidad predicha de exceder el umbral sanitario de tres hembras adultas de *L. salmonis* por pez, en los meses de enero, octubre y diciembre.

Gráficos




Fuente: Elaboración propia.

Se aprecia que, durante los primeros meses (enero a mayo), la proporción de registros que superan el límite de tres hembras adultas por pez es relativamente baja. A partir de agosto, la prevalencia comienza a incrementarse y alcanza sus valores máximos en setiembre y octubre, donde más del 10–15 % de las observaciones exceden el umbral. En noviembre y diciembre la proporción de incumplimientos disminuye, aunque se mantiene por encima de los niveles observados en la primera mitad del año. Este patrón descriptivo sugiere un componente estacional en el riesgo de incumplimiento, que luego es

capturado y ajustado en el modelo de regresión logística mediante la inclusión del mes como covariable.

Figura 2. Relación entre *L. salmonis* machos y riesgo de



Fuente: Elaboración propia.

Se muestra la relación entre la abundancia promedio por pez de estadios móviles no reproductivos de *L. salmonis* machos y la probabilidad predicha de exceder el umbral sanitario de tres hembras adultas por pez. Cada punto representa una observación individual del conjunto de datos, mientras que la línea suavizada (loess) refleja la tendencia general; además, se observa un incremento pronunciado del riesgo sanitario a medida que aumenta la abundancia de estadios móviles machos. Para valores bajos (< 3 por pez), la probabilidad de incumplimiento es cercana a cero; sin embargo, a partir de valores intermedios (5–8 por pez), el riesgo aumenta rápidamente y alcanza niveles casi máximos (> 0.9) cuando la abundancia supera las 10 unidades por pez. Este patrón es consistente con los resultados del modelo logístico, donde la abundancia de estadios móviles constituye el predictor más influyente del incumplimiento del umbral regulatorio.

5. Conclusiones

El presente estudio aplicó un modelo de regresión logística binaria para predecir la probabilidad de exceder el umbral sanitario de tres hembras adultas de *Lepeophtheirus salmonis* por pez en centros de cultivo marino, utilizando datos operacionales reportados al Departamento de Pesca y Océanos de Canadá entre 2011 y 2024. Los resultados mostraron que la abundancia de

estadios móviles no reproductivos de *L. salmonis* (machos) es el predictor más influyente del incumplimiento del umbral, lo que coincide con la dinámica biológica del parásito, dado que la presencia elevada de estadios móviles suele mostrar aumentos en la abundancia de hembras adultas.

El modelo presentó un desempeño sobresaliente, con valores altos de sensibilidad y especificidad en el conjunto de prueba (división 70/30), lo que evidencia una excelente capacidad de discriminación para identificar registros con riesgo sanitario elevado. Asimismo, la inclusión del mes como variable categórica permitió capturar patrones estacionales relevantes, mientras que las abundancias de *Caligus* spp. y el número de corrales muestreados contribuyeron de manera menor a la explicación del evento.

En términos aplicados, estos resultados sugieren que la regresión logística es una herramienta útil para apoyar la vigilancia sanitaria en centros de cultivo, permitiendo anticipar escenarios de alto riesgo y fortalecer la toma de decisiones relacionadas con tratamientos oportunos, planificación de manejo y cumplimiento regulatorio. Finalmente, se recomienda que trabajos futuros incorporen información ambiental (temperatura, salinidad, corriente) y modelos jerárquicos o mixtos que permitan capturar la variabilidad entre centros y entre ciclos productivos.

6. Referencias bibliográficas

A continuación, se listan las referencias utilizadas en la sección de antecedentes y trabajos relacionados, todas en formato APA.

- Boxaspen, K. (2006). A review of the biology and genetics of sea lice. *ICES Journal of Marine Science*, 63(7), 1304–1316. <https://doi.org/10.1016/j.icesjms.2006.04.017>
- Bravo, F., Oliveira, M., Parent, M. I., Korus, J., Scłodnick, T., Gardner, I., Whidden, C., Filgueira, R., Hammell, K. L., Swanson, A. K., Torgo, L., & Grant, J. (2025). Modeling dynamics of adult female lice at salmon farming sites in Eastern Canada: A stochastic, state-based approach. *Frontiers in Aquaculture*, 4, 1647026. <https://doi.org/10.3389/faquc.2025.1647026>
- Costello, M. J. (2006). Ecology of sea lice parasitic on farmed and wild fish. *Trends in Parasitology*, 22(10), 475–483. <https://doi.org/10.1016/j.pt.2006.08.006>

Elghafghuf, A., Vanderstichel, R., Hammell, L., & Stryhn, H. (2020). Estimating sea lice infestation pressure on salmon farms: Comparing different methods using multivariate state-space models. *Epidemics*, 31, 100394. <https://doi.org/10.1016/j.epidem.2020.100394>

Krkošek, M., Bateman, A. W., Proboszcz, S., & Orr, C. (2010). Dynamics of outbreak and control of salmon lice on two salmon farms in the Broughton Archipelago, British Columbia. *Aquaculture Environment Interactions*, 1(2), 137–146. <https://doi.org/10.3354/aei00014>

Revie, C. W., Gettinby, G., Treasurer, J. W., & Wallace, C. (2005). Evaluating the effect of clustering when monitoring the abundance of sea lice populations on farmed Atlantic salmon. *Journal of Fish Biology*, 66(3), 773–783. <https://doi.org/10.1111/j.0022-1112.2005.00642.x>

Revie, C. W., Patanasatienkul, T., McEwan, G., & Stewardson, L. (2025). Sea lice infestation dataset for wild and farmed salmon populations on the Pacific coast of Canada (2001–2023). *Scientific Data*, 12(1), 1331. <https://doi.org/10.1038/s41597-025-05653-x>

Stige, L. C., Qviller, L., Viljugrein, H., & Tavoranpanich, S. (2025). A salmon lice prediction model. *Preventive Veterinary Medicine*, 235, 106405. <https://doi.org/10.1016/j.prevetmed.2024.106405>

Torrissen, O., Jones, S., Asche, F., Guttormsen, A., Skilbrei, O. T., Nilsen, F., Horsberg, T. E., & Jackson, D. (2013). Salmon lice – impact on wild salmonids and salmon aquaculture. *Journal of Fish Diseases*, 36(3), 171–194. <https://doi.org/10.1111/jfd.12061>